

NAKAST — Manual de usuario

NAKAST — Manual de usuario

Versión 1.0 · Referencia completa para ejecutar e interpretar NAKAST.

Para una primera corrida en cinco minutos, vea el [README](#). Este manual asume que el pipeline ya está instalado y cubre lo que el README no: cómo leer los resultados, qué asume el pipeline sobre sus datos, y dónde están sus límites.

An English version of this manual is available at [USER_MANUAL.md](#).

Contenidos


Primeros pasos 1. [Qué hace NAKAST](#) 2. [Conceptos previos](#) 3. [Un ejemplo completo](#)

Uso del pipeline 4. [Especificación de entrada](#) 5. [Referencia de parámetros](#) 6. [Referencia de salidas](#) 7. [Cómo interpretar los resultados](#) 8. [Evaluación de la calidad de los datos](#)

Referencia 9. [Arquitectura del flujo](#) 10. [Cómo se llaman los alelos](#) 11. [Asignación de ST y CC](#) 12. [Especies soportadas](#) 13. [Supuestos](#) 14. [Limitaciones](#) 15. [Resolución de problemas](#) 16. [Reproducibilidad](#) 17. [Notas de diseño](#) 18. [Soporte, citación y licencia](#)

1. Qué hace NAKAST

NAKAST determina perfiles MLST a partir de lecturas de amplicones Oxford Nanopore. Usted entrega directorios de FASTQ y un nombre de especie; el pipeline devuelve una tabla de Sequence Types.



La especie actúa como **clave de agrupación**: la base de datos se descarga una vez por especie distinta, cada muestra se une a la base de su propia especie, y se emite un reporte por especie. Una misma corrida puede, por lo tanto, mezclar especies.

2. Conceptos previos

MLST (Multi Locus Sequence Typing) caracteriza un aislado bacteriano secuenciando un conjunto pequeño de fragmentos de genes housekeeping, habitualmente siete. Cada secuencia distinta en un locus recibe un **número de alelo** entero, curado centralizadamente.

Perfil alélico es el conjunto ordenado de números de alelo, por ejemplo 9-1-4-1-3-3-2.

Sequence Type (ST) es un entero asignado a cada perfil alélico distinto. Un perfil coincide con un ST solo si *todos* los alelos son coincidencia exacta con un alelo conocido. Un solo locus sin caracterizar deja el aislado sin tipificar.

Complejo Clonal (CC) agrupa STs emparentados que comparten la mayoría de sus alelos. No todos los esquemas definen complejos clonales: 102 de los 135 esquemas soportados lo hacen. El resto reporta CC = -, lo cual es correcto y no una falla.

PubMLST (<https://pubmlst.org>) aloja las secuencias de alelos de referencia y las tablas de perfiles. NAKAST consulta su API REST directamente, de modo que los resultados reflejan el estado actual de la base de datos.

KMA es el alineador. Mapea lecturas contra una base de datos de secuencias de alelos indexada por k-meros y reporta identidad, cobertura y profundidad por molde. Se adecúa a datos redundantes de amplicones porque resuelve cuál de muchos alelos casi idénticos explica mejor las lecturas.

3. Un ejemplo completo

Una corrida de tres aislados de *Streptococcus agalactiae*, desde los datos crudos hasta la interpretación.

Paso 1 — revisar los datos de entrada

Sus lecturas ya basecalled y demultiplexadas, un directorio por muestra:

```
ls ~/corrida_2026_03/fastq_pass/
# barcode01 barcode02 barcode03
ls ~/corrida_2026_03/fastq_pass/barcode01/ | head -3
# FBD86797_pass_barcode01_0.fastq.gz
```

Paso 2 — encontrar el nombre de la especie

```
nextflow run nakast.nf --list-species | grep -i agalactiae
# sagalactiae 1 7 yes Streptococcus agalactiae
```

Paso 3 — escribir el samplesheet

Tres columnas separadas por tabulación:

```
printf 'sample_id\tfastq_dir\tspecies\n' > samplesheet.tsv
printf 'SGB11\t%s/barcode01\t%sagalactiae\n' ~/corrida_2026_03/
fastq_pass >> samplesheet.tsv
printf 'SGB12\t%s/barcode02\t%sagalactiae\n' ~/corrida_2026_03/
fastq_pass >> samplesheet.tsv
printf 'SGB13\t%s/barcode03\t%sagalactiae\n' ~/corrida_2026_03/
fastq_pass >> samplesheet.tsv
```

Use rutas absolutas. Las rutas relativas se resuelven contra el directorio desde el que se lanza la corrida.

Paso 4 — ejecutar

```
nextflow run /ruta/a/nakast/nakast.nf \
--samplesheet samplesheet.tsv \
--outdir resultados_corrida2026_03
```

Espere entre 5 y 10 minutos para tres muestras en un notebook, la mayor parte en KMA. La primera corrida suma unos minutos extra para construir los ambientes Conda; las siguientes los reutilizan.

Paso 5 — leer el reporte

Sample	ST	CC	adhP	pheS	atr	glnA	sdhA	glcK	tkf	Profile
SGB11	10	cc12	9	1	4	1	3	3	2	OK
SGB12	24	cc452	5	4	4	3	2	3	3	OK
SGB13	2	cc1	1	1	3	1	1	2	2	OK

Tres aislados tipificados: ST10, ST24 y ST2. La sección 7 explica qué hacer cuando una fila no se parece a estas.

Paso 6 — revisar el control de calidad

Abra `resultados_corrida2026_03/qc/multiqc_report.html` para confirmar que los conteos de lecturas y las distribuciones de calidad son los esperados para la corrida.

4. Especificación de entrada

Un archivo separado por tabulaciones, con fila de encabezado y tres columnas.

Columna	Requerida	Descripción
<code>sample_id</code>	sí	Identificador único. Se usa como prefijo de los archivos de salida
<code>fastq_dir</code>	sí	Directorio con archivos <code>.fastq.gz</code> o <code>.fastq</code>
<code>species</code>	sí	Nombre corto del catálogo, por ejemplo <code>sagalactiae</code>

Las columnas adicionales se ignoran, de modo que los samplesheets escritos para versiones anteriores siguen funcionando.

La validación corre antes de cualquier trabajo pesado y verifica que existan las tres columnas, que `sample_id` no esté vacío y sea único, que los directorios referenciados existan en disco, y que `species` figure en `assets/pubmlst_species.tsv`. Una especie mal escrita falla en segundos con una sugerencia, en vez de hacerlo tras una descarga parcial.

Un lote de especies mezcladas se escribe exactamente igual:

```
sample_id    fastq_dir    species
SGB11        /datos/corrida1/barcode01    sagalactiae
SAL07        /datos/corrida1/barcode02    salmonella
```

5. Referencia de parámetros

Entrada y salida

Parámetro	Por defecto	Descripción
--samplesheet	<code>samplesheet.tsv</code>	Tabla de entrada
--outdir	<code>results</code>	Directorio base de salida
--qc_outdir	<code><outdir>/qc</code>	Salidas de control de calidad
--consensus_outdir	<code><outdir>/consensus_sequences</code>	FASTA consenso
--report_outdir	<code><outdir>/reports</code>	Archivos .res y tablas de perfiles
--mlst_report	<code>mlst_profiles</code>	Nombre base del reporte final

Filtrado de lecturas

Parámetro	Por defecto	Descripción
--nano_base_quality	20	Calidad Phred mínima, entregada a chopper
--min_length	300	Longitud mínima de lectura (filtlong)
--keep_percent	80	Conservar este porcentaje de las mejores lecturas por bases (filtlong)

Llamado de alelos

Parámetro	Por defecto	Descripción
--min_depth	30	Profundidad mínima, aplicada en KMA y de

Parámetro	Por defecto	Descripción
		nuevo en el script de reporte
--min_identity	90	Identidad mínima respecto del alelo de referencia (%)
--allele_coverage	90	Cobertura mínima del alelo, es decir del molde (%)
--kma_k	31	Tamaño de k-mero para el índice de KMA
--generate_consensus	true	Publicar las secuencias consenso por locus

Modos de ejecución

Parámetro	Por defecto	Descripción
--qc_only	false	Solo control de calidad; sin descarga ni tipificación
--list_species	false	Imprimir el catálogo de especies soportadas y salir
--help	false	Imprimir la ayuda y salir

Opciones de Nextflow que conviene conocer

Pertenecen a Nextflow y llevan un solo guion.

Opción	Propósito
-resume	Reutilizar el trabajo completado en la corrida anterior
-profile host	Usar las herramientas del PATH en vez de Conda
-with-report	Reporte HTML de ejecución adicional

Recursos

Se asignan por etiqueta en `nextflow.config`. Edite ese archivo según su máquina.

Etiqueta	CPUs	Memoria	Tiempo	Procesos
<code>process_low</code>	2	4 GB	2 h	validación, base de datos, listado de especies
<code>process_medium</code>	6	10 GB	8 h	concatenación, filtrado, QC, reporte
<code>process_high</code>	12	16 GB	24 h	alineamiento con KMA

6. Referencia de salidas

```
results/
├─ mlst_profiles_<especie>.txt      ← el resultado
├─ mlst_profiles_<especie>.xlsx
├─ qc/
│   └─ qc_<muestra>/
│       └─ multiqc_report.html      ← calidad de la corrida
├─ consensus_sequences/
│   └─ <muestra>.fsa
├─ reports/
│   └─ <muestra>.res                ← evidencia por alelo
│       └─ <especie>_profiles.tsv
└─ pipeline_info/
```

Qué archivo responde cada pregunta

Pregunta	Archivo
¿Qué ST tiene mi aislado?	<code>mlst_profiles_<especie>.txt</code>
¿Por qué se llamó así este alelo?	<code>reports/<muestra>.res</code>
¿Secuenció bien la corrida?	<code>qc/multiqc_report.html</code>
¿Qué secuencia envió a PubMLST o confirmo por Sanger?	<code>consensus_sequences/<muestra>.fsa</code>

Pregunta	Archivo
¿Qué versión de PubMLST usó esta corrida?	reports/<especie>_profiles.tsv
¿Cuánto demoró, qué falló?	pipeline_info/

Columnas del reporte final

Columna	Contenido
Sample	Identificador de la muestra
ST	Sequence Type, o - si el perfil no coincide con ninguno
CC	Complejo Clonal, o - si no está asignado o el esquema no lo define
una columna por locus	Llamado del alelo con su anotación de calidad
Profile	OK, o INCOMPLETE (n/N) cuando se recuperaron menos de N loci

Archivos intermedios

- reports/<muestra>.res — salida cruda de KMA. El registro autoritativo de identidad, cobertura, profundidad y puntaje para cada molde considerado.
- reports/<especie>_profiles.tsv — la tabla de perfiles de PubMLST exacta que se usó. Consérvela: PubMLST cambia con el tiempo y este archivo permite reproducir la corrida después.
- consensus_sequences/<muestra>.fsa — consenso de KMA por locus.
- pipeline_info/ — reporte de ejecución, línea de tiempo y traza.

7. Cómo interpretar los resultados

Recorra esto en orden cuando una fila no sea un OK limpio con su ST.

Las anotaciones de alelo

Notación	Significado
9	Coincidencia exacta con el alelo 9
~9	El más cercano es el alelo 9, pero la secuencia difiere
9?	Coincide con el alelo 9, pero la lectura es más larga que la referencia
INS	La lectura cubre menos que el alelo completo
-	Sin llamado: bajo los umbrales de identidad, cobertura o profundidad

Solo los enteros sin anotación pueden coincidir con un perfil de PubMLST. Es el dato más útil de este manual. Si cualquier locus lleva ~, ?, INS o -, el perfil no puede coincidir y ST será -. La búsqueda del ST no falló; el perfil simplemente estaba incompleto.

Guía de decisión

ST = - pero todos los loci tienen un entero sin anotación. El perfil está completo pero esa combinación no existe en PubMLST. Es un ST genuinamente nuevo. Considere depositarlo.

ST = - y un locus muestra ~N. El caso más frecuente. Ese locus difiere de todos los alelos conocidos. O es un alelo nuevo, o el consenso arrastra un error de secuenciación. Para distinguirlos, revise la profundidad de ese locus en el archivo .res. Una diferencia consistente a alta profundidad apunta a un alelo nuevo real; confírmelo por Sanger usando el consenso de consensus_sequences/. Una diferencia a baja profundidad es más probablemente un artefacto.

ST = - y un locus muestra -. Ese locus no se recuperó. Revise su profundidad en el archivo .res. Una profundidad bajo --min_depth significa que el amplicón rindió mal, lo cual es un problema de laboratorio y no de análisis. Reamplifique o secuencie más profundo.

Profile = INCOMPLETE (6/7). Se recuperaron seis de siete loci. El diagnóstico es el mismo: identifique el locus faltante y revise su profundidad.

ST asignado pero CC = -. Habitualmente es correcto. Muchos STs no tienen complejo clonal, y 33 de los 135 esquemas no definen ninguno. Revise la columna CC del catálogo para su especie.

Todas las muestras con ST = -. Sospeche del valor de *species* antes que de los datos. Tipificar contra el esquema equivocado produce resultados vacíos sin ningún error.

Cómo leer el archivo de evidencia

```
column -t results/reports/SGB20.res | head
```

Las columnas que importan son #Template (locus y alelo), Template_Identity, Template_Coverage, Query_Coverage y Depth. Un alelo llamado ~9 mostrará Template_Identity bajo 100. Un locus reportado como - puede estar ausente del archivo por completo, lo que significa que nada pasó los umbrales.

8. Evaluación de la calidad de los datos

NAKAST no impone un umbral de calidad más allá de `--min_depth`. Use estos puntos de referencia, obtenidos en la validación con el panel de amplicones propio del ISP para *S. agalactiae*.

Métrica	Habitual	Preocupante
Profundidad por locus	de varios cientos a algunos miles	bajo 100
Loci recuperados	7 de 7	6 o menos
Alelos anotados por muestra	0	2 o más
Calidad mediana de lectura	alrededor de Q18	bajo Q12

La profundidad varía bastante entre loci en un panel de amplicones: una diferencia de diez veces entre el mejor y el peor amplicón es normal. Lo que importa es que el locus más débil supere `--min_depth`.

Una profundidad muy alta no rescata una amplificación deficiente. Si un locus es consistentemente débil en todas las muestras de una corrida, la causa está en el partidador o en la reacción, no en el análisis.

9. Arquitectura del flujo

Proceso	Herramienta	Propósito
VALIDATE_SAMPLESHEET	python, pandas	Verificación previa del samplesheet
DOWNLOAD_PREP_DB	python, kma	Detectar esquema, descargar alelos y perfiles, indexar
concat_ONT_fastq	coreutils, gzip	Unir un directorio de barcode en un solo FASTQ
FILTER_ONT	filtlong, chopper	Filtrado por longitud y calidad
NANOPLLOT	NanoPlot	Control de calidad por muestra
MULTIQC	MultiQC	Reporte de calidad agregado
KMA_RUN	kma	Alinear lecturas contra la base de alelos
GENERATE_REPORT	python, pandas, openpyxl	Llamado de alelos, asignación de ST y CC, reportes
LIST_SPECIES	python	Imprimir el catálogo de especies soportadas

El comportamiento ante fallas difiere por etapa, de forma deliberada:

Proceso	Estrategia	Razón
VALIDATE_SAMPLESHEET	terminate	Un samplesheet inválido debe detener todo de inmediato
DOWNLOAD_PREP_DB	3 reintentos, luego finish	Sobrevive cortes de red transitorios; deja terminar el QC para que -resume pueda continuar
KMA_RUN, GENERATE_REPORT	terminate	Una falla silenciosa aquí produciría una corrida sin resultados y exit 0
concat_ONT_fastq, FILTER_ONT, NANOPLLOT, MULTIQC	ignore	Una muestra mala no debe abortar el lote

10. Cómo se llaman los alelos

Paso 1 — filtro de profundidad

Los moldes bajo --min_depth se descartan, tanto en KMA como nuevamente en el script de reporte.

Paso 2 — elegir un ganador por locus

Varios alelos del mismo locus suelen atraer lecturas, ya que difieren en unas pocas bases. NAKAST los ordena con un puntaje de confianza:

$$\text{Score_Ratio} = \text{Score} / \text{Expected}$$

$$\text{Confidence} = \text{Score_Ratio} \times \log_{10}(\text{Depth}) \times \text{bonus_perfecto}$$

bonus_perfecto vale 1.5 cuando identidad, cobertura del molde y cobertura de la consulta son todas 100%, y 1.0 en caso contrario. El molde con mayor confianza gana el locus.

El bonus es multiplicativo y no absoluto a propósito: una coincidencia perfecta todavía necesita profundidad que la respalde, de modo que una sola lectura bien alineada no puede superar a un alelo con cobertura profunda.

Paso 3 — anotar el llamado

Notación	Condición
9	Identidad, cobertura del molde y de la consulta, todas 100%
~9	Cobertura de consulta y molde 100%, identidad bajo 100%
9?	Cobertura de consulta sobre 100%, identidad y cobertura sobre los umbrales
INS	Cobertura de consulta bajo 100%
-	Identidad o cobertura del molde bajo los umbrales, o ningún molde pasó

Una nota sobre ?: una cobertura de consulta sobre 100% significa que la lectura es *más larga* que el molde. Con un panel de amplicones esto refleja read-through y no truncamiento, así que el llamado suele ser correcto. Interprete 9? como “probablemente el alelo 9, vale la pena confirmarlo” y no como una falla.

11. Asignación de ST y CC

Los llamados de alelo se unen en una firma (9/1/4/1/3/3/2) que se compara contra la misma firma construida a partir de la tabla de perfiles de PubMLST. La comparación es exacta y sobre texto:

- Los loci provienen de <especie>_loci.txt, escrito desde la definición del esquema, y luego se ordenan como aparecen en la tabla de perfiles, de modo que el reporte conserva el orden canónico de PubMLST.
- La tabla de perfiles se lee como texto para que un valor faltante no convierta en silencio una columna de locus en números decimales

y produzca 1.0/1/2/..., lo que haría fallar todas las comparaciones.

- La columna de CC se detecta de forma tolerante (clonal_complex, clonal complex, cc, clonalcomplex). Si no existe, CC = -.
- Si no hay coincidencia se devuelve ST = -. **NAKAST nunca reporta un ST cercano o aproximado.**

12. Especies soportadas

assets/pubmlst_species.tsv y docs/supported_species.md catalogan los **135 esquemas de PubMLST** que definen perfiles ST. Para regenerarlos:

```
python3 bin/list_pubmlst_species.py --write-catalogue .
```

Dos supuestos que se cumplen para *S. agalactiae* pero no en general, y que NAKAST por lo tanto resuelve en tiempo de ejecución:

- **El esquema MLST no siempre es el número 1.** Siete esquemas usan otro identificador; *Salmonella* usa el 2. NAKAST selecciona el esquema cuya descripción comienza con MLST.
- **Los esquemas no siempre tienen siete loci.** Van de 2 a 10, y 48 de 135 difieren de siete. La lista de loci proviene de la definición del esquema, nunca de una lista fija.

Los nombres de locus también son menos regulares de lo que parecen: MLST_adk, 16S_rRNA e int_hyp contienen guiones bajos, por lo que los identificadores de alelo se separan por la derecha.

13. Supuestos

Estos importan para interpretar los resultados.

1. **Secuenciación de amplicones, no genoma completo.** Se asume que las lecturas provienen de amplificación dirigida de los loci MLST. Se espera profundidad de cientos o miles, y los umbrales por defecto reflejan eso. Datos de genoma completo darán una profundidad por locus mucho menor y muchos llamados -.
2. **La especie se conoce y se declara.** NAKAST no identifica el organismo; tipifica la muestra contra el esquema que usted

especifique. Una species equivocada produce un resultado vacío, no un error.

3. **PubMLST está accesible y es la fuente autoritativa.** La base se descarga fresca en cada corrida, de modo que los resultados dependen del estado de PubMLST en ese momento. Por eso la tabla de perfiles se publica junto con las salidas.
4. **El esquema define perfiles ST.** Los esquemas sin clave primaria, como cgMLST, quedan fuera del catálogo y se rechazan al momento de la descarga.
5. **Los identificadores de muestra son únicos** en todo el samplesheet. Dan nombre a los archivos de salida.
6. **Las lecturas están basecalled y demultiplexadas.** NAKAST parte de FASTQ por barcode. No hace basecalling, ni demultiplexado, ni recorte de adaptadores y barcodes.
7. **Un organismo por muestra.** Cultivos mixtos o contaminados producen alelos en competencia en algunos loci; el puntaje de confianza elegirá uno, y una anotación ~ suele ser la única señal visible.

14. Limitaciones

1. **Solo Oxford Nanopore.** No hay ruta para lecturas cortas. Los parámetros de filtrado y alineamiento están afinados para el perfil de error de ONT, y el samplesheet recibe un directorio de archivos FASTQ y no pares de lecturas.
2. **No detecta ni deposita alelos nuevos.** Una secuencia ausente de PubMLST se reporta como ~N contra el alelo conocido más cercano. NAKAST no la marcará como nueva, no propondrá un número ni preparará un depósito. La confirmación, por Sanger por ejemplo, es un paso manual; el consenso en consensus_sequences/ es el punto de partida.
3. **Requiere red.** No hay modo sin conexión ni caché local entre corridas. Cada corrida vuelve a descargar el esquema.
4. **Validado biológicamente en una sola especie.** La arquitectura es agnóstica de especie y se ejercitó contra los esquemas de *Salmonella*, *Brucella*, *Vibrio* y *Mycoplasma genitalium*, pero la validación contra aislados conocidos se hizo solo para *S. agalactiae* con el panel de amplicones propio del ISP. Los parámetros de alineamiento están afinados para ese panel.

5. **Los complejos clonales dependen del esquema.** 33 de 135 esquemas no definen ninguno, y aun donde existen, muchos STs no tienen CC.
6. **No detecta contaminación ni muestras mixtas.** No hay una verificación explícita de alelos múltiples en un mismo locus.
7. **Los umbrales de profundidad son globales.** `--min_depth` se aplica por igual a todos los loci. Un panel donde un amplicón rinde sistemáticamente mal puede requerir bajar el umbral para toda la corrida.
8. **Un reporte por especie.** Los lotes que abarcan varias especies producen varios archivos en vez de una tabla única, porque las columnas de loci difieren.

15. Resolución de problemas

Unknown configuration profile: 'conda' — Conda está habilitado por defecto; quite el flag `-profile conda`.

command not found / exit status 127 — el proceso corrió contra el PATH del sistema en vez de su ambiente Conda. Confirme que `nextflow.config` .reporte `conda { enabled = true }` y que ningún `nextflow.config` suelto en su directorio de lanzamiento lo esté sobrescribiendo.

Variable declarations cannot be mixed with config statements — un `nextflow.config` en su directorio de lanzamiento usa sintaxis que Nextflow 26 rechaza. Nextflow fusiona el config del directorio de lanzamiento con el del pipeline, así que un config ajeno de un proyecto viejo romperá la corrida. Lance desde un directorio limpio.

Todos los ST son - — revise primero el valor de `species`, después las columnas de alelo. Vea la [sección 7](#).

La validación rechaza la especie — ejecute `--list_species` y use el nombre corto exacto. El mensaje de error sugiere coincidencias cercanas.

Falla la descarga — el pipeline reintenta tres veces antes de detenerse, y deja terminar el QC en curso. Vuelva a correr con `-resume` cuando se restablezca la conexión; el trabajo completado se reutiliza.

No se cachea nada con `-resume` — verifique que nada en las entradas de las tareas cambie entre corridas. Interpolar un objeto `Path` como `launchDir` directamente en el script de un proceso le da un hash inestable; páselo como entrada `val`.

Falta una muestra en el reporte — su paso de filtrado o de QC falló y se ignoró para que el lote continuara. Busque `Error is ignored` en el log de Nextflow y revise `pipeline_info/` para ver qué proceso falló.

16. Reproducibilidad

Cada proceso declara su propio ambiente Conda con versiones exactas:

Proceso	Ambiente
VALIDATE_SAMPLESHEET	python=3.13.11 pandas=2.3.3
DOWNLOAD_PREP_DB, KMA_RUN	python=3.13.11 kma=1.6.8
concat_ONT_fastq	python=3.13.11 coreutils=9.5 gzip=1.12
FILTER_ONT	python=3.13.11 filtlong=0.3.1 chopper=0.12.0 gzip=1.12
NANOPLLOT	python=3.13.11 nanoplot=1.46.2
MULTIQC	python=3.13.11 multiqc=1.33
GENERATE_REPORT	python=3.13.11 pandas=2.3.3 numpy=2.4.0 openpyxl=3.1.5
LIST_SPECIES	python=3.13.11

Los ambientes se cachean en `$HOME/.nextflow/conda` y se construyen con `mamba`. Las especificaciones idénticas comparten un mismo ambiente.

La única entrada que *no* está fijada es `PubMLST`, que cambia a medida que los curadores agregan alelos y STs. Para reproducir una corrida pasada, conserve `reports/<especie>_profiles.tsv` y la traza de `pipeline_info/` junto al reporte.

17. Notas de diseño

Se registran aquí dos hallazgos del ajuste contra datos reales de *S. agalactiae*, porque son contraintuitivos y fáciles de reintroducir. Esta sección apunta a quien mantenga el código, no a quien lo use.

El `-mrc` de KMA no es cobertura del alelo. `-mrc` es *minimum query coverage*: la fracción de la **lectura** que debe alinear. Una versión anterior le pasaba `--allele_coverage`. Con lecturas de alrededor de 950 pb contra amplicones de 500 pb, la mayoría de las lecturas no puede alcanzar 90% de cobertura de consulta. Los loci con lecturas abundantes sobrevivían igual, pero los loci poco amplificados perdían todas sus lecturas y desaparecían pese a ser coincidencias perfectas al 100% de identidad y cobertura. El flag se eliminó; la cobertura del alelo se controla aguas abajo sobre `Template_Coverage`, que es donde corresponde.

Los umbrales de calidad de `filtlong` no están en escala Phred. `--min_mean_q` y `--min_window_q` toman un porcentaje de exactitud de 0 a 100, así que pasarles 20 no filtra absolutamente nada (Q20 corresponde a 99). Fijarlos en un valor que sí filtre resultó perjudicial: en 95 los loci poco amplificados perdieron todo su soporte, porque los loci de baja abundancia también tienden a llevar las lecturas de peor calidad. Los flags se eliminaron y la calidad se controla únicamente con `chopper`, en escala Phred, mediante `--nano_base_quality`.

Un resultado negativo relacionado: escalonar umbrales de calidad (Q30 → Q25 → Q20) no es viable con datos típicos de amplicones ONT. Con una calidad mediana por lectura cercana a Q18, los umbrales sobre Q22 aproximadamente retienen una fracción de un por ciento de las bases, y los fragmentos sobrevivientes son más cortos que un amplicón, por lo que no pueden cubrir un alelo.

18. Soporte, citación y licencia

Reportar problemas. Abra un issue en https://github.com/javiertognarelli/bio_pipelines/issues. Incluya la versión de Nextflow (`nextflow -version`), el comando que ejecutó, y la parte relevante de `.nextflow.log`.

Autoría. NAKAST — Javier Tognarelli, Genómica UV. Encargo del ISP (Daniel Escobar, Fernando Amaya). Panel de diseño propio, ISP 2025.

Citar NAKAST. Cite este pipeline junto con PubMLST y las herramientas subyacentes. La lista completa de componentes de terceros y sus licencias está en [THIRD_PARTY_LICENSES.md](#).

Fuente de datos. Las definiciones de alelos y perfiles provienen de PubMLST (<https://pubmlst.org>), alojado en la Universidad de Oxford. Reconozca a PubMLST y al esquema correspondiente en cualquier publicación que use estos resultados.